三向扫描：两篇肤色测量论文

WHY / HOW / WHAT 比较 · 2026-10-08 · academic-research-skills `deep-research` three-way-scan 模式

这是同一问题的两个相反答案：第一篇让算法从像素算出深浅和色相两个数；第二篇让人按 10 级量表标注，并研究怎样标才可靠。

	论文 1	论文 2
标题	Beyond Skin Tone: A Multidimensional Measure of Apparent Skin Color	Consensus and Subjectivity of Skin Tone Annotation for ML Fairness
来源	Thong、Joniak、Xiang（Sony AI、东京大学）；arXiv:2309.05148v2，2023-10-03，预印本	Schumann 等（Google、Harvard）；NeurIPS 2023 Datasets & Benchmarks，经同行评审
链接	https://arxiv.org/abs/2309.05148	https://doi.org/10.52202/075280-1320

WHY：为什么做

	论文 1	论文 2
要解决的问题	Fitzpatrick 只有深浅一个维度，标注主观；ITA 只用 L* 和 b*，与专家标注相关性低（§2–3）	肤色标注主观，受光照和标注者生活经验影响；标不准会把模型偏差归错原因（§1）
动机例子	随年龄增长，亚洲人皮肤变深且更黄，白种人变深且更红，深浅捕捉不到（§1）	36 级色卡认知负担太重，Fitzpatrick 偏向浅肤色，所以用 10 级的 MST（§2）
立场	只测“表观肤色”，也就是模型看到的颜色，光照包含在内	要的是标注者排除光照后判断出的肤色（§5、§7）

HOW：怎么做

	论文 1	论文 2
测量	皮肤分割 → CIELAB → K-Means 分 5 组 → 取直方图众数 → 去掉最暗的 2 组。得到 L*（深浅）和 h*（红↔黄），阈值 60 和 55°	人工标注 MST 1–10 级，用多人标注的中位数
数据	CelebAMask-HQ（3 万）、FFHQ（7 万）、CFD（739 张）、LFW（1,000 对）、CelebAMask-HQ 改图（4×3 万）	新建 MST-E：19 位模特、1,515 张图、31 段视频，4 小时内拍完，涵盖不同光照
评估对象	StyleGAN3 和 P2 生成图、Twitter 裁剪、ArcFace、FaceNet、Dlib、AWS、Azure、Clarifai、FairFace	10 位摄影师（印度和美国各 5）；众包标注者（印度、菲律宾、巴西、匈牙利、加纳，每地区 5 人，每张图 25 个标注）；再加 8.7 万张 Open Images 人脸
标准答案	无	量表创建者 Monk 一人（§3）
统计	t 检验加 Bonferroni 校正、Elo 评分	ICC、Mann-Whitney、MANOVA、Spearman-Brown

WHAT：发现了什么

论文 1

- **数据集偏向浅色、偏红：** 浅肤色占比 CelebAMask-HQ 74.4%，FFHQ 66.3%；偏红占比 66.2% 和 81.9%。StyleGAN3 和 P2 照搬了这个偏差（表 1、2）。
- **裁剪算法有偏好：** 偏好浅色，比深色高 60.73%；偏好偏红，比偏黄高 58.25%；p 均小于 0.0001（图 3）。
- **人脸验证差距不大：** 三个模型都更擅长识别浅肤色和偏红的人。边际组差距 0.3–1.1 个百分点，交叉组最大 4.2 点（表 3）。
- **色相影响独立于深浅：** 笑容分类中，把皮肤调红的影响比调亮还大（Azure 不笑组准确率：调红降 11.1 点，调亮降 4.5 点）。变亮会让男性更容易被判成女性（AWS 男性准确率 94.82→90.66）（表 4）。

论文 2

- **摄影师标得准：** 与标准答案相差 1 级以内的比例，印度 88.9%、美国 83.4%（§5）。
- **众包标注者一致性高：** 按人算的 ICC 为 0.86–0.94。5 个地区合起来，19 人中有 18 人（94.7%）在标准答案 1 级以内。好光照和差光照下，平均中位距离都是 0.78（§6）。
- **地区影响显著：** MANOVA 显示地区有影响（Pillai's trace = 1.97，$p<0.05$）。同一位模特，印度摄影师多标 MST3–5，美国摄影师多标 MST5–7。
- **标注者数量：** 光照好的图，每地区 1 人（共 5 人）够用；光照差的图，每地区 2 人（共 10 人）。
- **野外数据：** Open Images 上 ICC 为 0.875–0.91，与 MST-E 无显著差别（§6）。
- **像素法失败：** 把皮肤像素取 RGB 平均再匹配色块，自动检测的结果几乎都落在 6–8 级，与真实肤色无关（图 10a）。
- **建议：** 至少 5 个地区、每地区至少 2 位标注者；部署在哪个地区，就优先用当地标注者；用覆盖全色阶的例子培训标注者（§7）。

方法弱点

> 仅供参考，不构成评分。标注说明：[作者承认] 指论文自己写明的局限，附章节位置；[读者推断] 指本报告根据全文推断、未经检验的判断。

论文 1（实证研究；读了全文含附录）

- **检查清单：** 研究假设清晰度没有发现问题；变量操作化定义、内部效度、外部效度、统计报告完整性、结论保守度都发现了问题。
- **作者自己承认的局限** [作者承认，A.1、§4.3]：表观肤色受光照、色偏、化妆影响；重建和操纵会改变背景、视线等属性；商业模型发布晚于 Gender Shades，偏差可能已缩小。
- **度量没有对照基准：** 没有和分光光度计或人工标注（Fitzpatrick、Monk）在同一批图上比较（已查 §3、§4.1–4.3、A.2–A.4）。§3 说“更可靠、更客观”只是论证，没有检验。系统性误差会被记成群体差异。[读者推断]
- **色相稳健性证据窄：**
  - 光照稳健性只用一个人的 8 张重打光图（图 S3）。
  - 图 S1 的 5 个干扰示例里，4 个 h* 是负值（−25.38、−14.70、−0.70、−4.22），超出文中关注的 0–90°。文中没说明负值怎么归组（已查 §3、§4.1、A.2、A.4）。
  - 如果归入“红”，偏色和低光的图会抬高红色占比。[读者推断]
- **阈值依赖采集条件：**
  - 55° 取自皮肤仪文献，用在野外照片上，而 L* 在重打光下偏移约 6 点。

- 同一阈值在不同数据集给出的红黄比差别很大：CelebAMask-HQ 约 66/34，FFHQ 约 82/18，CFD 约 28/72（图 3b，n=206/533）。[读者推断]

- **裁剪实验是观察性的：** 肤色与族裔、性别、发型、妆容一起变。Elo 评分来自同一批对局，彼此不独立，却用了独立样本 t 检验。[读者推断]
- **统计与操纵细节缺：**
  - 表 3 没有各组样本数、置信区间和显著性。
  - 因果实验里，分类器的标签来源和操纵幅度没说明，正交性只用图 4 的少数样本展示（已查 §4.3、A.2）。
  - 表 4b 只有 AWS 和 Azure 两个系统。[读者推断]
- **“P2 略放大偏差”只对色相成立：** 偏红 81.87%→83.37%，但浅肤色占比反而从 66.26% 降到 65.30%（表 1b、2b）。[读者推断]

论文 2（实证研究；读了全文 30 页，含附录和审稿回应）

- **检查清单：** 研究假设清晰度没有发现问题（§6 明确写了假设）；变量操作化定义、内部效度、外部效度、统计报告完整性、结论保守度都发现了问题。
- **作者自己承认的局限** [作者承认，§7 Limitations、附录 L]：没考虑其他身份因素、任务语言、界面；MST-E 只有 19 人；摄影师部分是探索性的；5 地区之外的情况未知。
- **“10 级量表比其他量表更好”没有检验：** 审稿人问过量表长度的影响，作者答复“超出本文范围”[作者承认，附录 L]。所以 MST 比 Fitzpatrick 更好这个前提，本文没有在同一批图上比较过。[读者推断]
- **标准答案来自一个人：** 标准答案是 Monk 一人的判断（§3）。多地区标注的中位数“符合量表本意”，实际是“符合一个人的判断”。如果他的感知恰好接近某些地区，一致度就会偏向那些地区。[读者推断]
- **“1 级以内”掩盖了系统性压缩：**
  - 全球混淆矩阵（图 8，三种统计口径）显示，浅端往深偏、深端往浅偏：标准答案是 MST1 的，最常被标成 2（42–44%），标成 1 的只有 19–38%；标准答案是 MST2 的，约 60% 标成 3。
  - 标准答案是 MST10 的，被标成 10 的只有 2–8%，多数标成 8（Golden 50%，按人算 51%）或 9（Challenging 66%）。
  - 论文只报“1 级以内”比例（18/19），没说明哪一位不在范围内。矩阵显示 MST10 那一行最可能是这位。
  - 1 级的容忍度沿用 Fitzpatrick 六级研究的做法（§4）。10 级量表上的 ±1 和 6 级量表上的 ±1 并不等价。
  - 数据卡显示 MST7 和 MST10 各只有 1 位模特（附录 C）。深色一端的证据很薄。[读者推断]
- **“不受光照影响”的证据薄：**
  - 摄影师部分，Golden 组总是先标，Challenging 组一周后才标，光照与先后顺序完全重合（§5）。
  - 众包部分，“光照差”只有 19 张人工挑选的图，没有量化光照程度（§3、§6）。
  - 图 3a 中，美国摄影师在 Challenging 组的 ICC 约 0.68，Golden 组约 0.83（读图估计）。[读者推断]
- **培训材料没说明：** 文中说众包标注者“受过 MST 培训”，但没说培训用了什么图（已查 §4、§6、§7、附录 D 的界面截图、附录 K）。如果培训用了 MST-E 的图，培训集和测试集就重叠了。[读者推断]
- **野外数据只证明了“一致”，没证明“标得对”：** Open Images 没有标准答案，只报了 ICC 和地区差异（§6）。ICC 与 MST-E 无显著差别（p=0.99），不等于两者相同。§7 说结果“能推广到其他领域”，超出了这部分证据。[读者推断]
- **统计报告不全：** 摄影师部分做了 36 次检验，其中 3 次 $p<0.05$，没做多重比较校正，按 5% 水平纯偶然也预计出现约 1.8 次；MANOVA 没报具体哪些地区之间差多少；ICC 没有置信区间（已查 §5、§6、附录 E）。[读者推断]

跨论文综合

共同的 WHY

- 两篇都认为 Fitzpatrick 不适合当肤色量表：它为晒伤反应设计，偏向浅肤色（论文 1 §2；论文 2 §2、附录 A.2）。
- 都承认光照会改变图像里的肤色（论文 1 附录 A.1；论文 2 §1）。
- 都发现主流数据偏浅色：论文 1 中 CelebAMask-HQ 有 74% 是浅肤色；论文 2 中 Open Images 的 MST2–4 约占三分之二（图 6，读图估计）。

分歧的 HOW

	论文 1	论文 2
谁来测	算法	人
测的是什么	图像里呈现的颜色，光照算进去	人认为这个人是什么肤色，光照被排除
维度	深浅加红黄色相，两个连续维度	只有 10 级一个维度
标准答案	没有	Monk 一人
成本	不需要人工	众包标注约 78 万美元（附录 K）
对对方的看法	人工标注主观、有偏差	像素法受光照影响，在野外不可靠

两篇测的不是同一个东西，结果不能直接互换。引用关系上，论文 1 的 §2 用一句话把论文 2 列为同期工作；论文 2 没有引用论文 1。

最强的 WHAT

- **证据最扎实的是论文 2：** 人工 MST 标注在 5 个地区、8.7 万张野外人脸上重复验证，一致性高。但证明的是“一致”，不是“准确”。
- **最有新意的是论文 1：** 色相会造成独立于深浅的模型偏差。但度量本身没有验证，因果实验又依赖生成模型来改图。
- **两篇之间有张力：** 论文 1 把人工标注描述为主观、不可靠；论文 2 发现训练过的人工标注一致性高，但也显示了系统性压缩和地区差异。“人工标注是否可靠”，两篇各说对了一半。

没解决的问题

- **两种度量没对照过：** 没有人在同一批图上同时测 L*/h* 和 MST 人工标注，所以不知道 L* 和 MST 等级怎么对应。
- **色相能否被人可靠标注：** 论文 1 不用人，论文 2 只有深浅一个维度。
- **光照处理相反，没验证：** 一篇把光照算进肤色，一篇把它排除，没有人检验这个选择会不会改变公平性检查的结论。
- **都没有独立的标准答案：** 论文 1 没有任何参照，论文 2 的标准答案是一个人。

阅读范围和限制

- **读了什么：** 两篇都读了全文。论文 2 的 30 页文字全读了，并核对了其中的图和表（图 3、5、6、8、10，附录 D、E）。论文 1 的表 1–4 和图 3 对照过渲染页。
- **数字的来源：** 带“读图估计”的是从图上读的。混淆矩阵的数字是放大后读出的，口径是论文原图所用的百分比。

- **没做的事：** 没有外部检索，没核查两篇的参考文献是否真实存在，定位用章节号而不是页码。

附注：MST-E 数据集的使用条款

项目文件夹里的 `mst-e_data.zip` 就是论文 2 发布的数据集。它的 README 写明，只能用于研究或人工标注员培训，不能用来训练机器学习模型。论文 §3 还写了“模型评估”，但 README 没写这一项。用于其他用途前，请先确认条款。

AI 使用声明：本报告由 Claude（Anthropic）通过 academic-research-skills 插件的 deep-research three-way-scan 模式生成。所有数字和章节位置均来自两篇论文原文；标注为 [读者推断] 的内容是 AI 的推断，未经检验，引用前请自行核对原文。